

Deepfake Image Detection via Temporal Attention Mechanism

2019124018 Donghyeon Kim 2020124040 Jiwoo Nam

항공전자정보공학부
Korea Aerospace University

서론

최근 GAN 및 확산 모델과 같은 생성 모델의 발전은 매우 사실적인 합성 이미지의 생성을 가능하게 한다. 이러한 기술은 다양한 분야에 긍정적인 영향을 미칠 수 있지만, 동시에 이미지의 진위 여부를 판단하기 어려워지는 등 심각한 보안 및 사회적 문제를 야기한다. 본 연구에서는 확산 기반 위조 이미지의 탐지를 위한 접근법으로 Attention 메커니즘을 제안한다. 제안된 방법은 확산 모델의 복원 과정 중 발생하는 시간적 패턴을 활용하여 위조 이미지의 미세한 이상 징후를 포착하는 것이다. Multi-Head Self-Attention(MHSA)을 통해 시간적 의존성을 모델링하고, 공간적 중요도를 반영한 가중치 맵을 활용하여 의미 있는 특징을 강조한다.

1. 소개

최근 몇 년간 딥러닝 기반 생성 모델을 바탕으로 이미지 생성 분야는 급격하게 발전하였다. 대표적인 모델인 GAN(Generative Adversarial Networks)과 확산 모델(Diffusion Models)은 매우 사실적인 이미지 생성은 이러한 발전을 가능하게 하였다. 특히 확산 모델의 경우 무작위 노이즈를 역확산 과정을 통해 점진적으로 제거함으로써 이미지를 생성하는 확률적 생성 모델로 기존의 GAN 기반 모델들보다 우수한 성능을 보이며 이미지 합성 기술의 발전을 주도하고 있습니다. 이는 예술, 디자인, 의료 영상 등 다양한 분야에 활용되고 있다. 그러나 해당 기술의 발전은 '딥페이크(Deepfake)'와 같이 정교한 위조 이미지의 생성에도 사용되며, 사회적 혼란 및 보안 위협으로 이어질 수 있는 문제를 야기하고 있다.(Figure 1)

기존의 이미지 위조 탐지 기법들은 주로 주파수 영역이나 공간 영역에서 이미지의 통계적 아티팩트나 시각적 단서(질감, 가장자리, 지역적 불일치 등)를 분석하는 방식을 사용해왔다. 하지만 최근 확산 모델 기반으로 생




Figure 1. (a) 확산 모델(Diffusion model)로 생성된 이미지와 (b) 생성적 적대 신경망(GAN)으로 생성된 이미지.

성된 위조 이미지는 단계적인 노이즈 제거 과정을 거쳐 매우 자연스러운 결과물을 생성하기 때문에, 시각적으로 위조 여부를 식별하기가 매우 어려워졌다. 이로 인해 기존의 전통적인 탐지 방법만으로는 한계가 있음이 분명하다.

이에 본 연구에서는 Attention 메커니즘을 활용하여 확산 모델로 생성된 위조 이미지를 탐지하는 두 가지 접근 방식을 제안한다. 우리가 제안하는 방법들은 공통적으로 확산 모델의 복원 과정 중 발생하는 아티팩트를 추출하는 데 중점을 둔다. Multi-Head Self-Attention (MHSA)을 통해 시간적 의존성을 모델링하고, 공간적 중요도를 반영한 가중치 맵을 활용하여 의미 있는 특징을 강조함으로써 진위 여부를 더욱 정밀하게 판단할 수 있도록 설계하였다.

첫 번째 방법인 Temporal Attention Features (TAF)는 확산 모델의 역방향 과정 중 노이즈를 제거하면서 단계별로 발생하는 중간 표현의 특징에서 Attention Map을 추출한다. 이 방법은 확산 모델의 디노이징 과정에서 발생하는 이미지의 내재된 속성, 즉 의

미론적 구조 보존력의 차이를 활용하여 진짜 이미지와 가짜 이미지를 구별하는 것을 목표로 한다.

두 번째 방법인 Temporal Overdenoising Difference (TOD)는 노이즈 제거가 완료된 이미지를 몇 차례 더 과잉 제거(overdenoising)하여 각 디노이징 단계별 차이를 분석하고 이를 바탕으로 Attention Map을 추출하는 방식이다. 이 두 방법론은 모두 확산 모델의 특성을 활용하여 생성된 콘텐츠를 식별하는 데 기여한다.

2. 관련 연구

확산 모델은 이미지 생성 분야에 혁신적인 발전을 가져왔을 뿐만 아니라, 기존 탐지 기법으로는 식별이 어려운 생성 이미지에 대한 탐지 가능성도 제시하고 있다. 본 장에서는 확산 모델의 개요를 살펴보고, 이를 기반으로 한 이미지 위조 탐지 관련 연구 동향을 정리한다.

2.1 확산 모델: Stable Diffusion

확산 모델은 이미지 생성을 위한 확률적 생성 모델로 원본 이미지에 점진적으로 노이즈를 추가하는 순방향 과정과 이 노이즈를 제거해 이미지를 복원하는 역방향 과정으로 구성된다. 특히, Stable Diffusion은 이 과정을 잠재 공간에서 수행함으로써 연산 효율성과 품질을 동시에 확보한 대표적인 모델이다.

순방향 과정(Forward process)

원본 이미지 x_0 에 대해, 시간 단계 $t \in \{1, \dots, T\}$ 에서 노이즈가 추가된 이미지 x_t 는 다음과 같은 확률적 정의를 따른다:

$$q(x_t | x_0) = N(x_t; \alpha_t x_0, (1 - \alpha_t))$$

이때 α_t 는 시간 단계에 따른 감쇠 계수이며, 일반적으로 선형 또는 코사인 스케줄을 통해 조절된다.

역방향 과정 (Reverse Process)

모델은 훈련을 통해 각 시간 단계에서 x_t 로부터 원본 이미지 x_0 를 복원하도록 학습한다. 이를 위해 노이즈 예측 함수 $\epsilon_\theta(x_t, t)$ 를 사용하여 노이즈를 제거하고, 다음과 같은 방식으로 복원을 수행한다.

$$p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

Stable Diffusion은 위와 같은 과정을 고해상도 이미지를 생성한다.

2.2 확산 기반 생성 이미지 탐지

기존의 생성 이미지 탐지 기법은 주로 GAN 기반 위

조 이미지에 초점을 맞추고 있어, 확산 모델로 생성된 이미지에 대한 탐지 성능은 상대적으로 낮은 편이다. 확산 모델은 단계적인 노이즈 제거 과정을 거치며 보다 자연스러운 결과물을 생성하기 때문에, 시각적으로 위조 여부를 식별하기가 매우 어렵다.

이에 따라 최근에는 확산 기반 이미지의 중간 복원 단계 또는 잠재 표현을 활용한 탐지 기법들이 제안되고 있다. 예를 들어, 복원 오차나 디노이징 궤적의 불일치(Denoising Trajectory Discrepancy)를 분석함으로써 위조 여부를 판단하는 방식이 연구되고 있다.

본 연구에서는 이러한 선행 연구를 바탕으로 시간과 공간 축의 정보를 활용하여 위조된 이미지에서 나타나는 미세한 시공간적 불연속성 특징을 포착하는 방법을 제안한다.

2.3 Attention

입력 시퀀스 내의 특정 부분에 가중치를 부여함으로써, 모델이 보다 중요한 정보에 집중할 수 있도록 설계된 구조이다. 처음 제안된 이 메커니즘은, 특히 긴 시퀀스에 대해 고정된 크기의 벡터로 정보를 요약하는 기존 인코더-디코더 구조의 한계를 극복하는 데 큰 기여를 하였다. Attention은 디코더가 각 시점에서 인코더의 모든 출력(hidden states)과의 유사도를 기반으로 가중 평균(context vector)을 계산하고, 이를 현재 시점의 입력으로 활용함으로써 정보 손실을 최소화한다.

이후 다양한 형태의 Attention(예: global, local)이 제안되며 구조적 다양성을 확장하였고, 더 나아가 Self-Attention을 기반으로 한 Transformer 아키텍처를 통해 시퀀스 모델링의 새로운 패러다임을 제시하였다. 이처럼 Attention은 자연어 처리뿐만 아니라 영상 처리, 시계열 분석 등 다양한 분야에서 핵심적인 구성 요소로 자리 잡고 있으며, 최근에는 시간적 또는 공간적 정보의 중요도를 반영하는 모듈로도 널리 활용되고 있다.

3. 생성 이미지 탐지 방법론

이 섹션에서는 딥페이크 이미지 탐지를 위해 제안된 두 가지 방법에 대해 자세히 설명한다. 두 방법 모두 확산 모델의 특성을 활용하여 생성된 콘텐츠를 식별한다.

3.1 Temporal Attention Features

TAF 모델은 디퓨전 모델의 디노이징 과정에서 추출한 중간 어텐션 맵으로 생성 모델 탐지를 수행하며, 다음 네 가지로 분류기를 구성한다.

특징 추출

디퓨전 모델의 U-Net은 디노이징을 통해서 이미지를 재구성합니다. 이 과정에서 U-Net의 중간 레이어에서 어텐션 특징 맵 $F \in \mathbb{R}^{H' \times W' \times C'}$ 를 추출한다. 여기서 H'




Figure 2. Temporal Attention Features의 개요

'와 W '는 특징 맵의 크기, C '는 채널 수를 의미한다. 중간 레이어는 풀 어텐션(full attention) 메커니즘을 이용하여 이미지의 전역적인 노이즈 정보와 고수준의 의미론적 구조를 모두 포함하는 풍부한 특징을 생성한다. 이러한 특징은 생성 이미지와 실제 이미지 간의 아주 작은 차이를 구별하는 데 매우 중요한 역할을 한다.

Temporal MSHA

Temporal MSHA 은 디노이징 스텝에 따른 특징 맵의 변화를 분석한다. 다양한 시간 단계 $t \in \{0, \dots, T-1\}$ 에 걸쳐 추출된 특징 맵 시퀀스 $\{F_t | t=0 \sim T-1\}$ 는 3D 텐서 $temporal \in \mathbb{R}^{T \times H' \times W' \times C'}$ 로 구성된다. Multi-Scale Hierarchical Attention (MSHA) 기법을 적용하여 시간 축 특징들 간의 상호 의존성을 학습하고, 노이즈 제거 과정에서 생성 이미지가 나타내는 시간적 고유 패턴 또는 흔적을 포착한다. MSHA 내에서, 각 시간 단계 t 의 특징 F_t 에 대해 Query (Q_t), Key (K_t), Value (V_t)는 다음과 같이 생성된다:

$$Q_t = F_t W_Q, K_t = F_t W_K, V_t = F_t W_V$$

어텐션 스코어는 다음과 같이 계산된다:

$$\text{Attention}(Q, K, V) = \text{softmax}(\text{dk } QKT)V$$

MSHA는 이를 h 개의 어텐션 헤드로 확장하여 각 헤드의 결과를 병합하여 최종 출력 $O_{temporal}$ 을 생성한다.

$$\text{Head}_i = \text{Attention}(QWQ_i, KWK_i, VWV_i)$$

$$\text{MSHA}(F_{temporal}) = \text{Concat}(\text{Head}_1, \dots, \text{Head}_h)WO$$

Spatial MSHA

공간적 특징 파이프라인은 입력 이미지 $F_{spatial} \in \mathbb{R}^{H' \times W' \times C'}$ 내의 중요한 공간적 영역에 집중한다. 특징 맵을 시간 축으로 평균과 최대 값으로 모아 두개의 특징을 생성한다. 특징 맵은 1×1 Convolution과 3×3 Dilated Convolution을 통해서 로컬 영역의 특징을 학

습한다. MSHA를 활용하여 전역 공간 정보를 학습하여, 특징 맵의 공간적 전역 정보를 효과적으로 포착할 수 있다. MSHA의 출력에 Feed-Forward Network (FFN)가 적용되어 더욱 풍부한 표현을 생성한다.

$$\text{FFN}(X) = \text{MLP}(\text{Conv}(X)), \text{Ospatial} = \text{SoftMax}(X)$$

최종 출력은 Ospatial이다.

분류기 (Classifier)

Temporal MSHA의 출력 $O_{temporal}$ 과 Spatial MSHA의 출력 $O_{spatial}$ 은 곱셈을 통해 최종 특징 벡터 F_{final} 을 형성한다:

$$F_{final} = \text{Combine}(O_{temporal}, O_{spatial})$$

이 결합된 특징은 이진 분류기에 입력되어 이미지를 생성 이미지($y^*=1$) 또는 실제 이미지($y^*=0$)로 최종으로 탐지한다:

$$y^* = \sigma(W_c * F_{final} + b)$$

생성 이미지 탐지 방법론

TAF 모델은 디퓨전 모델의 디노이징 과정에서 중간 레이어 어텐션의 이미지의 전역적 정보와 의미론적 변화를 분석하여 생성 이미지를 탐지한다. U-Net 중간 레이어의 self-attention 특징 활용이 이 방식의 핵심이다.

실제 이미지와 생성 이미지는 디퓨전 모델의 디노이징 및 이미지 재구성 과정에서 풀 어텐션을 통해 이미지 내 모든 픽셀 (i, j) 와 (k, l) 간의 상호작용을 직접적으로 계산하고, 이미지 전체의 문맥 정보를 이해하고 노이즈가 만들어내는 전역적 패턴 정보를 가장 효과적으로 포착한다:

$$\text{Attention}(Q, K, V)_{i,j=k,l} = \sum \text{softmax}(\text{dk } Q_{i,j} K_{k,l}^T) V_{k,l}$$

중간 레이어의 어텐션은 전역적인 노이즈 정보뿐만




Figure 2. Temporal Attention Features의 개요

아니라, 이미지의 풍부한 의미론적 구조를 반영한다. 생성 모델은 특정 의미론적 구조를 학습하여 이미지를 생성하며, 이 구조는 디노이징 과정에서 선명하게 나타난다. 실제 이미지는 잠재 공간에 인코딩 될때 의미론적 구조가 덜 명확하게 반영되거나 다른 정보까지 포함하여 왜곡될 수 있다. 중간 레이어의 어텐션 메커니즘은 이러한 구조적 일관성 또는 불일치를 효과적으로 학습하여 생성 모델 탐지에 기여한다.

결론

TAF 모델은 디퓨전 모델의 디노이징 과정에서 발생하는 생성 이미지와 실제 이미지 간의 본질적인 차이를 효과적으로 활용하여 딥페이크를 탐지한다. 특히, U-Net의 중간 레이어에서 추출되는 시간 및 공간적 어텐션 특징의 분석은 이미지의 전역적 정보와 의미론적 변화를 효과적으로 포착하며, 이는 생성 이미지 고유의 생성 흔적을 식별하는 데 매우 중요한 역할을 한다.

3.2 Temporal Overdenoising Difference

OD(Temporal Overdenoising Difference)는 확산 기반 생성 이미지 탐지를 위해 제안된 새로운 접근 방식으로, 오버 디노이징(overdenoising) 과정에서 발생하는 시공간적 차이를 추출하여 진위 여부를 판단한다. 기존의 복원을 위한 디노이징과 달리, 본 방식은 디노이징을 몇 차례 더 적용함으로써 생성 이미지와 실제 이미지 간의 구조적 및 의미론적 불일치를 유도하고, 이를 Attention 기반 메커니즘으로 정밀하게 분석한다.

오버 디노이징 기반 탐지 전략

디퓨전 모델은 기본적으로 일정한 시간 스케줄을 따라 노이즈를 제거하며 이미지를 점진적으로 복원한다. 하지만 이러한 복원은 주어진 시간 범위 내에서만 수행되며, 복원이 완료되면 노이즈 제거 과정이 중단된다. TOD는 이 점에 착안하여, 정상적인 디노이징 종료 이

후에도 몇 차례 추가적인 denoising step을 적용하는 전략을 사용한다. 이 과정을 통해 이미지 내 의미론적 정보와 구조가 파괴되는데, 특히 실제 이미지의 경우 latent 공간과의 부정합으로 인해 이러한 붕괴가 두드러지게 나타난다. 반면, 생성 이미지는 latent 공간에서 직접 생성되었기 때문에 오버 디노이징 상황에서도 비교적 구조 보존이 잘 유지된다.

오버 디노이징 특징 추출

특징은 이미지에 "과잉 제거(overdenoising)" 과정을 적용한 후 추출된다. 일반적인 노이즈 제거 과정은 원본 이미지를 복원하는 데 초점을 맞추지만, "과잉 제거"는 의도적으로 노이즈 제거를 지나치게 적용하여 이미지에 미묘한 변형이나 인공적인 흔적을 남긴다. 본 기법에서는 이미지를 20단계 이상 추가로 디노이징하여 중간 표현 $\{ \}_{t=-+1}^{T+k}$ 을 생성한다. 이때의 특징맵들은 다음과 같은 특성을 가진다.

- 실제 이미지: 구조적 왜곡, 의미론적 패턴 붕괴
- 생성 이미지: 구조적 일관성 유지

시공간 특징 정렬

Attention 연산을 적용하기 위해 각 특징맵 시퀀스를 다음과 같은 방식으로 벡터화한다.

1. 공간 평탄화

$$F_t \in R^{H \times W \times C} \quad F'_t \in R^{P \times C}, \text{ where } P=H \cdot W$$

2. 시간 채널 결합

$$\{F'_t\} \quad X \in R^{P \times (CT)} = R^{P \times D}$$

이는 각 위치 p에서 시간-채널 축으로 연속적인 시퀀스를 갖는 벡터로 변환되는 형태이다. 결과적으로, 픽셀 위치별로 시공간 정보를 가지는 시퀀스가 구성된다.

Diffusion Model Evaluation									
Method	ADM	BigGAN	GLIDE	MidJourney	SDv1.4	SDv1.5	VQDM	Wukong	Mean
NPR	78.2%	82.5%	98.3%	95.7%	100.0%	99.9%	86.5%	99.9%	92.6%
FreqNet	52.7%	51.3%	53.5%	56.2%	99.9%	99.9%	54.2%	99.8%	70.9%
DIRE	50.9%	50.2%	55.0%	60.2%	99.9%	99.8%	50.1%	99.2%	70.7%
LaRE	61.7%	68.7%	88.5%	74.0%	100.0%	99.9%	97.2%	100.0%	86.2%
Baseline	62.3%	70.2%	89.6%	75.2%	100.0%	99.9%	98.5%	100.0%	87.0%
Ours_TRE	46.9%	53.4%	63.3%	59.0%	83.2%	83.7%	58.0%	80.5%	66.0%
Ours_TAF	49.8%	56.6%	65.1%	59.2%	85.3%	85.4%	60.0%	82.1%	68.0%
Ours_TOD	48.7%	52.8%	66.0%	59.1%	85.3%	87.6%	61.7%	79.8%	68.4%

Multi-Head Self-Attention 적용

재구성된 텐서 $\in D$ 에 대해 Multi-Head Self Attention(MHSA)을 적용하여 각 위치 간의 상호작용 및 시간-채널 정보 간의 상관관계를 학습한다. Attention 계산식은 다음과 같다:

$$\text{Attention}(Q, K, V) = \text{softmax}_k(QK^T)V$$

$$\text{MHSA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_2)W^O$$

각 head는 고유한 학습 파라미터를 통해 서로 다른 관점에서 정보를 추출하며, 다중 관점의 특징을 통합하여 보다 풍부한 표현을 구성한다.

특징 결합 및 분류기

MHSA를 통해 생성된 attention 출력은 feedforward layer를 거쳐 최종 특징 벡터로 정제된다. 이를 기반으로 이진 분류기를 설계하여, 입력 이미지가 실제(real)인지 생성(fake)인지 판별한다.

TOD와의 차이점

TOD는 기존의 attention 기반 탐지 기법들과는 달리, 의도적으로 구조적 불균형을 유도한 후 그 차이를 attention으로 분석한다는 점에서 차별성이 있다. 생성 이미지가 latent space에 적합한 반면, 실제 이미지는 과잉 디노이징 시 의미론적 정보 손실이 두드러지게 나타나며, 이로 인해 두 클래스 간의 feature gap이 명확하게 발생한다. 이 차이는 디노이징 과정의 시간 축을 따라 누적적으로 증가하며, self-attention을 통해

그 차이를 모델이 효과적으로 학습하게 된다.

4. 실험

본 섹션에서는 제안된 생성 이미지 탐지 방법론인 TAF와 TOD 성능을 평가하기 위한 실험 설정 및 결과를 제시한다.

4.1 실험 설정

데이터셋

확산 모델(Diffusion Model) 기반의 이미지에 대한 탐지 성능을 평가하기 위해 다양한 확산 모델로 생성된 이미지를 포함하는 데이터셋을 활용하였다. 평가에 사용된 확산 모델은 ADM, BigGAN, GLIDE, MidJourney, SDv1.4, SDv1.5, VQDM, Wukong 등 총 8가지이다. 훈련에는 SDv1.4 6만장을 사용했으며, 평가에는 1.2만장씩 총 9만6천개의 테스트셋을 사용했다.

평가 지표

각 방법론의 성능은 탐지 정확도(Accuracy)를 사용하여 측정하였다. 정확도는 모델이 생성 이미지를 생성 이미지로, 실제 이미지를 실제 이미지로 올바르게 분류한 비율을 의미한다.

비교 방법론

제안하는 방법론(Ours_TAF, Ours_TOD)의 성능을 객관적으로 평가하기 위해 베이스라인 방법론들과 비교 실험을 진행하였다.

4.2 실험 결과 전반적인 성능

Ours_TRE, Ours_TAF 그리고 Ours_TOD 방식은 기존의 NPR, FreqNet, DIRE, LaRE, 그리고 Baseline 방법론에 비해 전반적으로 평균 정확도가 낮다. Ours_TRE는 66.0%의 평균 정확도를 기록했으며, Ours_TAF와 Ours_TOD는 각각 68.0%, 68.4%의 평균 정확도를 보였다. 이는 가장 높은 평균 정확도를 보인 NPR (92.6%) 및 Baseline (87.0%) 과 비교하여 성능 개선이 필요함을 의미한다.

모델별 성능 차이

SDv1.4 및 SDv1.5: 흥미롭게도 우리가 제안한 방법을 포함한 대부분의 방법론이 SDv1.4와 SDv1.5 모델에 대해서는 매우 높은 정확도 (80%대 중반에서 100%)를 달성했다. 이는 이들 모델로 생성된 이미지가 다른 확산 모델에 비해 탐지하기 쉬운 고유한 특징을 가질 수 있음을 의미한다.

ADM, BigGAN, GLIDE, MidJourney, VQDM, Wukong: 이들 모델에 대해서는 Ours_TRE, Ours_TAF 그리고 Ours_TOD의 정확도가 상대적으로 낮았다.(40%대 후반에서 80%대 초반). 이는 해당 모델들이 생성하는 이미지의 복잡성이나 다양성이 더 높거나, 탐지하기 어려운 특징을 내포하고 있을 가능성을 의미한다.

4.3 분석

TAF: 디노이징 과정의 MSHA에서 발생하는 의미론적 구조 보존력의 차이를 활용하여 진짜 이미지와 가짜 이미지를 구별하는 것을 목표이다. STRE에서 제안된 MHSAT(Multi-Head Self-Attention Temporal) 기반의 시공간 특징 추출 및 분류기 구조를 재현하여 기준 성능을 확보하고 있다. 이후 STRE 분류기의 단점(높은 계산량, 전역적 정보 학습에 치우침)을 개선하기 위해 MHSA 헤드 수를 줄이고(4번에서 2번으로), Batch Normalization을 추가하며, 지역적 정보 학습을 위한 Convolution 모듈을 삽입하여 TAF 분류기 모델을 제작하여 결과를 평가하였다.

TOD: 오버 디노이징 과정에서 발생하는 실제 이미지와 생성 이미지 간의 차이를 이용하여 생성 이미지 탐지를 목표로 한다. 특히, 과잉 제거를 통해 드러나는 잔차 노이즈 패턴과 구조적 불일치를 Multi-Head Self Attention (MHSA)을 통해 분석함으로써, 기존 방법론이 간과할 수 있는 특징을 식별하고자 한다. 이는 TAF

와 같이 Attention 아키텍처를 사용하지만, 특징 추출 방식과 집중하는 정보의 측면에서 차별점을 둔다.

한계점:

Ours_TRE, Ours_TAF 그리고 Ours_TOD는 STRE의 Baseline(평균 87.0%)보다 성능이 훨씬 낮았다. 이는 원본 STRE 논문에서 제시된 모델의 강점을 현재 TAF의 특징 데이터가 충분히 살리지 못하고 있거나, 혹은 TAF 설계 과정에서 도입된 변경 사항들(MHSA 헤드 수 축소, Convolution 추가 등)이 예상과 달리 성능 저하를 초래한 것으로 예상된다.

Ours_TAF의 성능 저하 원인

- 노이즈 민감도 저하: 전역 어텐션이 생성 영상의 핵심 단서인 미세한 아티팩트나 노이즈 패턴을 평균화하거나 부드럽게 만들어 탐지 민감도를 떨어뜨린다.
- 주요 정보 손실: 모델의 중간 레이어에서 고수준의 의미론적 정보가 미세한 노이즈 정보를 억압하여 필요한 정보를 가릴 수 있다.
- 어텐션의 한계: 정적인 어텐션으로는 Diffusion 과정의 복잡하고 동적인 시간적 변화 패턴을 완전히 포착하기 어려울 수 있다고 생각한다.

Ours_TOD의 성능 저하 원인

- 과도한 정보 손실: (노이즈 스텝보다 20step을 더 진행하는) 과잉 제거 과정은 실제 이미지와 생성 이미지 모두에서 원본 이미지의 중요한 시각적 정보를 과도하게 손실시키거나 변형시킨다. 특히, 실제 이미지의 경우 자연스러운 질감이나 미세한 디테일이 인위적으로 제거되어 생성 이미지와 구분이 어려워질 것으로 예상된다.
- 고유한 아티팩트의 희석: 생성 이미지 고유의 미묘한 아티팩트들이 과잉 제거 과정에서 다른 형태의 노이즈나 변형으로 대체되거나, 오히려 일반적인 이미지 특징으로 희석되어 구별력이 약화될 수 있다. 확산 모델마다 아티팩트 생성 방식이 다른데, 일률적인 과잉 제거 스텝이 모든 생성 이미지에 효과적이지 않을 수 있다.
- 노이즈 패턴 분석 부족: TOD 역시 주의 메커니즘에서 노이즈 패턴에 대한 명시적 분석이 부족하다. MHSA가 생성 이미지의 노이즈 분포 및 통계적 특성을 효과적으로 포착하지 못할 수 있다.

5. 참고자료

1. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. International Conference on Learning Representations (ICLR).
2. Luong, M.-T., Pham, H., & Manning, C. D. (2015). Effective Approaches to Attention-based Neural Machine Translation. Conference on Empirical Methods in Natural Language Processing (EMNLP).
3. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is All You Need. Advances in Neural Information Processing Systems (NeurIPS).
4. Tran, A. T., Duan, H., Zhao, Z., & Feng, J. (2023). Revealing the Implicit Noise-based Imprint of Generative Models. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).
5. Liu, B., Wang, C., Cao, T., Jia, K., & Huang, J. (2024). Towards Understanding Cross and Self-Attention in Stable Diffusion for Text-Guided Image Editing. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).
6. Yu, Z., Liu, Y., Zhang, M., Wang, X., & Yang, Y. (2023). LaRE²: Detecting Diffusion Models via Latent Reconstruction Error.
7. Ren, Z., Qin, Y., Liu, Y., Niu, Y., & Yang, Y. (2023). STRE: Spatial-Temporal Reconstruction Error for Diffusion-Based Fake Image Detection.
8. Choi, H., Kang, S., Kim, S., & Kim, H. (2023). DIRE: Detection via Implicit Reconstruction Error for Diffusion-Generated Images.
9. Tan, M., Zhao, L., Zha, S., Zhan, X., Liu, Z., & Loy, C. C. (2023). Learning on Gradients: Generalized Artifacts Representation for GAN-Generated Images Detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023.
10. Cozzolino, D., & Verdoliva, L. (2023). Towards Generalized Detection of GAN-generated Images via Noise Pattern Representation.
11. Liu, J., Deng, Y., Luo, P., Gao, C., & Lin, D. (2023). DIRE: Diffusion Reconstruction Error for Detecting Synthetic Images.